

基于 PIC 临床医学公开数据库的数据分析报告

数据分析项目

1 项目概述

本项目依托 PIC 临床医学公开数据库，完成临床数据读取、预处理、统计分析、疾病预测模型构建，并对模型效果开展评估可视化，探究各项生理指标与患病风险的关联规律。

2 数据读取

本次分析数据集包含年龄、性别、血压、血糖、胆固醇等临床指标，以及患病结局标签。原始数据共 10 行样本，7 项特征指标，数据格式规范可直接加载调用。

3 数据预处理

针对临床数据常见问题开展清洗操作：剔除重复样本、中位数与均值填充缺失数值、过滤异常年龄数据、将性别文本类别转换为数值编码。清洗后数据无无效异常样本，满足后续分析建模条件。

4 统计分析

4.1 样本分布分析

通过患病分布统计可知样本患病与健康人群构成比例；年龄分布体现受试人群年龄区间集中范围，贴合常规临床调研人群特征。

4.2 指标相关性分析

相关性热图直观展示各生理指标间关联程度，血压、血糖等指标相互存在正向关联，指标变化具备协同性特征。




Figure 1: 疾病患病分布统计




Figure 2: 患者年龄分布直方图

4.3 组间差异对比

分组统计结果显示，患病组人群年龄、血压、血糖均值普遍高于健康组，此类指标异常升高与发病存在潜在关联。

5 预测模型建立

采用随机森林分类算法构建疾病患病预测模型，以各项生理指标为输入特征，患病标签为预测目标。按 7:3 比例划分训练集与测试集，完成模型训练拟合，算法适配小样本临床数据分类任务。

6 模型评估与可视化

6.1 ROC 曲线评估

ROC 曲线与 AUC 数值反映模型区分患病与健康样本的能力，数值越接近 1 代表预测性能越优。




Figure 3: 临床指标相关性热图




Figure 4: 模型 ROC 评估曲线

6.2 特征重要性分析

特征排序结果可筛选影响患病风险的核心生理指标，为临床筛查重点观测项目提供参考依据。

6.3 综合评估指标

准确率、召回率、F1 分数等指标综合判定模型整体预测效果，模型可有效依据生理指标判别患病风险。

7 总结结论

1. 血压、血糖、年龄指标和疾病发病关联性较高，是临床重点监测指标；2. 随机森林模型可实现基于常规体检指标的患病风险预测；3. 整套数据分析流程可复应用于同类临床医学数据库挖掘工作。




Figure 5: 特征重要性排序